

XGBoost와 SHAP을 활용한

서울시 아파트 단위면적당 매매가격의 설명 패턴 분석

Explanatory Patterns of Apartment Unit-Area Sale Prices in Seoul

한양대학교 부동산융합대학원 · 도시부동산정책전공
석사학위 중간발표

박현근

2026. 04

연구 배경 · 기존 문헌 3대 공백 · 본 연구의 차별성

75.2%

한국 가계 자산 중 실물자산 비중

통계청(2024) 가계금융복지조사. 서울 아파트는 자산 축적·주거 안정의 핵심 매개로, 가격 결정 구조 이해가 학술·정책적 과제.

기존 국내 서울 아파트 ML 연구의 3대 공백

공백 1

공간 단위 거친 집계

대부분 자치구(25개) 단위 → 동네 수준 이질성 유실

공백 2

단일 모형 예측 비교

OLS vs ML 성능 비교에 머무름 → SHAP 해석 체계 부재

공백 3

총가격 모형의 면적 독점

면적이 SHAP 상위 22% 독점 → 질적·입지적 신호 가려짐

축 1

단위면적 정규화

$$Y = \ln(\text{거래금액[만원]} / \text{전용면적[m}^2\text{]})$$

규모효과를 분모로 제거. 소형·대형 평형 간 단위가격 프리미엄을 독립변수로 보존(Malpezzi 2003, Sirmans et al. 2005 log-price 전통).

축 2

행정동 215개 세분화

자치구 25개 대비 약 8.6배

Nominatim 지오코딩 + GeoJSON 공간조인으로 법정동→행정동 매핑 파이프라인 구축. 세분화된 공간 단위에서 설명 패턴 탐색.

축 3

지역 별도 3모형

전체 · 강남3구 · 비강남 22개구

강남더미 제거한 17변수로 각 지역 독립 적합. 통합 모형 SHAP 재집계가 아닌 별도 모형으로 공간 이질성 실증.

데이터 · 18개 독립변수 체계

391,826

서울 아파트 매매 실거래

2019.01 ~ 2025.12 (84개월)

215

서울시 행정동

자치구 25개 8.6배 세분화

18

독립변수

물리 3 · 입지 2 · 환경 9 · 거시 4

물리 3

- 전용면적(m²)
- 층(층)
- 건물연령(년)

입지 2

- 강남구분(더미)
- 지하철역수(개)

환경 9

- 초/중/고교수
- CCTV수
- 백화점수(매장)
- 공원/도서관수
- 학원수/어린이집수 (구 단위 프록시)

거시 4

- 기준금리(%)
- CD금리(%)
- 소비자물가지수
- M2 광의통화

3가지 데이터 분할 · OLS · RF · XGBoost · SHAP

① 무작위

Random 70/10/20

학습 274,277 · 검증 39,183 · 테스트 78,366

📌 동일 단지 내 예측 성능

동일 단지 반복거래 공존 가능 → 낙관적 추정

② Group

단지 기준 분할

법정동 + 아파트명 기준 8,601 단지 · overlap = 0

📌 미경험 신규 단지 일반화 성능

단지 누수 차단 → 가장 보수적

③ 시간순

Chronological

학습 ≤ 2023.12 · 검증 2024.01-06 · 테스트 ≥ 2024.07

📌 미래 시점 예측 성능

시장 국면 이동(금리 인하 전환) 반영

세 모형 공통 평가 · 동일 하이퍼파라미터 · SHAP (TreeSHAP 5,000 샘플) 해석

OLS

선형 · 베이스라인

준탄력성 해석, 잔차 진단 Moran's I

Random Forest

배깅 · 분산 감소

$n=200$, $max_depth=15$, $min_leaf=5$

XGBoost

부스팅 · 편향 감소 · 대표 해석 모형

$max_depth=8$, $lr=0.1$, $rounds \leq 2000$, $early\ stop\ 50$

기술통계 · OLS 회귀 결과 (베이스라인)

1.90

x

강남 : 비강남 단위가격 배율

전체 평균 1,337.7 만원/m² · 중앙값 1,142.7

강남3구 2,207.5 / 비강남 22구 1,164.5

총가격 배율 2.20×보다 작음 → 강남 대형 평형 집중이
총가격 격차의 일부를 설명함을 단위면적 정규화가 실증

OLS 베이스라인 결과

$R^2 = 0.506$ | $\text{Adj } R^2 = 0.506$ | $N = 391,826$

단위가격 총 변동의 약 50.6%만 18개 변수의 선형 결합으로 설명 → OLS 선형
가정이 비선형 가격구조(재건축·입지 상호작용·국면 전환)를 충분히 포착하지 못함을
시사. 설명적 기준선으로만 활용.

OLS 주요 준탄력성 (log 계수 B, $(e^B - 1) \cdot 100\%$ 해석)

변수	B	t	준탄력성	해석
강남구분	+0.368	177.7	+44.46%	비강남 대비 강남 단위가격 차이
지하철역수	+0.061	104.8	+6.27%/역	역세권 프리미엄
도서관수	+0.028	27.3	+2.79%/개	문화 인프라 프리미엄
건물연령	-0.0035	-63.8	-0.35%/년	연식 1년당 단위가격 감소 (U자 반등 구간 존재)
어린이집수	-0.0182	-199.8	-1.80%/개	주거밀집지 혼재로 음의 계수(지역 별도 모형서 재검토)

모형별 · 분할별 예측 성능 (종속변수: log m²당 가격)

분할	OLS R ²	RF R ²	XGBoost R ²	XGB Median APE	XGB MAPE
무작위 (동일 단지 내)	0.5061	0.8937	0.9554	4.16%	6.73%
Group (미경험 단지)	0.4618	0.7414	0.8005	11.72%	15.52%
시간순 (미래 시점)	0.3939	0.6955	0.7972	12.61%	15.15%

관찰 1

일관된 서열: XGB > RF >> OLS

세 분할 모두에서 동일 서열. OLS R² 0.39~0.51 vs XGB 0.80~0.96 — 약 +0.30~0.45p 비선형 설명력 차이.

관찰 2

Group ≈ 시간순 (R² 차이 0.003)

Group 0.8005 vs 시간순 0.7972. 단지 누수 효과 (≈0.15p)가 국면 이동 효과보다 예측력에 더 큰 영향.

관찰 3

이원 기준 해석

무작위 R²=0.9554는 '동일 단지 내', Group/시간순 R²≈0.80은 '미경험 단지·미래 시점' 보수적 일반화 기준.

단위면적 정규화가 가져온 SHAP Top 6 재편

v6 총가격 모형 (log 거래금액)

1	전용면적	22.2%
2	강남구분	16.0%
3	건물연령	11.4%
4	M2 통화량	8.3%
5	백화점수	6.8%
6	어린이집수	5.2%

면적이 SHAP 상위 22% 독점 → 질적·입지적 신호 가려짐



v7 단위가격 모형 (log m²당 가격)

1	건물연령	12.43%
2	강남구분	11.74%
3	어린이집수 ★	11.53%
4	M2 통화량	10.77%
5	학원수 ★	9.61%
6	전용면적 (1→6)	9.55%

주거권(어린이집) · 사교육(학원) · 재건축(건물연령) 신호 전면화

핵심 변화 전용면적 1위 22.2% → 6위 9.55%로 규모효과 분리 · 거시(M2+CPI+금리) 통합 기여도 17.8% → 21.35%로 국면 민감도 증가

지역 별도 3모형 — 질적으로 다른 두 시장

강남 3구

n = 65,077 (16.6%)

XGB $R^2 = 0.9356$ · MedAPE 4.10% | OLS $R^2 = 0.379$

순위	변수	SHAP %
1	건물연령	16.46%
2	소비자물가지수	13.25%
3	백화점수	13.04%
4	전용면적	12.68%
5	M2	8.47%
15/17	어린이집수	1.69%

주도 축: 재건축 기대 · 상업 집적

압구정·대치·잠실 등 노후 단지 재건축과 명품·상업 집적이 단위가격을 주도. 어린이집·학원 프록시는 하위권.

비강남 22구

n = 326,749 (83.4%)

XGB $R^2 = 0.9421$ · MedAPE 4.07% | OLS $R^2 = 0.381$

순위	변수	SHAP %
1	건물연령	14.81%
2	소비자물가지수	11.79%
3	전용면적	11.19%
4	어린이집수	10.57%
5	M2	10.11%
6	학원수	8.63%

주도 축: 주거권 · 사교육 인프라 · 거시 유동성

어린이집·학원 프록시가 상위권에 진입 — 비강남 주거권 특성·사교육 수요가 단위가격 차별화 신호.

* 어린이집수 대비: 강남 15/17위 1.69% ↔ 비강남 4위 10.57% — 동일 변수가 지역에 따라 질적으로 다른 설명 역할

비선형 패턴 · Moran's I · Ablation

🎯 SHAP Dependence Plot — 비선형 패턴

건물연령 U자형

연령 증가 → SHAP 감소 기본 추세 위에, 25~30년 이상 구간에서 **반등 U자 패턴**.
재건축 기대·입지·표본 조합의 비선형 결합. OLS 선형 가정으로는 포착 불가.

전용면적 체감형

소형(40~60m²) SHAP +, 중·대형(85m²+) SHAP - 전환. 규모 정규화 후에도 **소형 프리미엄**이 비선형 체감 형태로 잔존.

📍 공간 자기상관 · Ablation

214개 행정동 잔차 · 같은 구 인접 가중 · 499 순열

진단	OLS	XGBoost
Moran I (잔차)	0.3247	0.0042
Z-score	8.882	0.252
p-value (순열)	< 0.001	0.880
Ablation ΔR^2 (학원·어린이집 제거)	-0.0542	-0.0004

→ XGB의 비선형 조합이 공간 구조 흡수

→ 프록시 두 변수 없이도 예측 구조 유지 (측정 한계 비왜곡)

핵심 OLS가 포착 못 한 **U자·체감·임계 비선형 패턴**을 XGBoost+SHAP이 정량 실증 — 공간계량 모형 없이 공간 구조 흡수 · 프록시 한계 비의존

학술·정책·실무 시사점 · 한계 및 향후 과제

학술적

XAI 국내 확장

단위면적 정규화 × 행정동(215) × 지역 별도 3모형 —
국내 부동산 XAI 문헌 최초 3축 결합

정책적

이원 시장 설계

강남=재건축·상업, 비강남=주거권·사교육. 가격 수준이
아닌 결정 구조 자체가 상이 → 지역별 차별 정책 시사

실무적

AVM 설명 책무

단위가격 SHAP 분해로 면적에 가려지지 않은 질적
프리미엄 투명화 — 감정평가·프롭테크 설명 책무 지원

▲ 연구의 한계

시설 변수 stock 병합 — 연도별 변동 미반영 **[교수 지적]**

- 학원·어린이집 구 단위 프록시 균등 배분 한계
- 도보 반경·최단거리 변수 미사용 (행정동 경계 count 기반)
- 질적 변수(브랜드·조망·재건축 단계) 미반영
- 공간계량(SAR/SEM) 직접 비교 미수행

향후 과제

- 연도별 시설 패널 (행안부·교육부 연간 스냅샷)
- GIS 기반 최근접 거리 변수 · Queen/Rook 경계 가중
- 평형대(60/85/132m²)별 m²단가 보조 분석
- LightGBM·CatBoost·TabNet 확장, LIME·ALE 교차 XAI
- 수도권·지방 대도시로 범위 확장 비교