

# XGBoost와 SHAP을 활용한 서울시 아파트 단위면적당 매매가격의 설명 패턴 분석

단위면적 정규화 · 행정동 분석 · 지역 별도 모형

한양대학교 부동산융합대학원 · 도시부동산정책전공

석사학위 중간발표 · 박 현 근

2026년 4월

# 발표 목차

01

## 서론

연구 배경, 필요성, 범위, 방법

02

## 이론 · 선행연구

헤도닉 · ML · XAI · 차별성

03

## 연구 설계

변수 · 분할 · 모형 · 강건성

04

## 실증 분석

기술통계 · SHAP · 지역 비교

05

## 결론

시사점 · 한계 · 향후 과제

본 발표의 핵심: 총가격이 아닌 단위면적당 가격으로 정규화하여, 규모효과에 가려져 있던 주거권·사교육·재건축 설명 신호를 드러낸다.

# 이

## 서론

1. 연구의 배경 및 목적
2. 연구의 범위 및 방법

# 왜 서울 아파트 단위가격인가

## 한국 가계의 현실

75.2%

한국 가계 자산 중 실물자산 비중

통계청 (2024) 가계금융복지조사

서울 아파트는 **자산 축적·주거 안정·거시경제**의 핵심 매개.

매매가격의 예측요인 파악은 학술·정책 모두 핵심.

## 기존 연구의 3대 공백

공백 1

**공간 단위 거친 집계**

대부분 연구가 자치구(25개) 단위 → 동네 수준 이질성 유실

공백 2

**단일 모형 예측 비교**

OLS vs ML 성능 비교에 머무름 → SHAP 해석 체계 부재

공백 3

**총가격 모형의 면적 독점**

면적이 SHAP 22% 독점  
→ 질적·입지적 신호 가려짐

# 본 연구의 3가지 차별성

## 축 1

### 단위면적 정규화

$$Y = \log(\text{거래금액} / \text{전용면적})$$

규모효과를 분모로 제거하여 질적·입지적 설명 신호 부각. 헤도닉 문헌의 log-price 전통에 연결.

## 축 2

### 행정동 세분화

215개 행정동 단위

자치구 25개 대비 8.6배 세분화. Nominatim 지오코딩 + GeoJSON 공간조인으로 매핑 방법론 구축.

## 축 3

### 지역 별도 모형

전체 · 강남3구 · 비강남 22개구

강남더미를 제거한 17변수 독립 적합. 지역 내부 설명 구조 직접 비교.

**연구 목적** — 서울 아파트 단위가격 결정의 숨은 질적 구조를 드러내고, AVM 실무의 **설명** 책무를 뒷받침하는 XAI 프레임워크 구축

# 연구 범위 및 데이터 스케일

391,826

아파트 매매 실거래

2019.01 ~ 2025.12 (84개월)

215

서울 행정동

25개 자치구 세분화

18

독립변수

물리 3 + 입지 2 + 환경 9 + 거시 4

## 4대 공공데이터 원천



국토교통부

실거래가 (data.go.kr)



서울열린데이터광장

지하철·백화점·공원·도서관·어  
린이집



NEIS

학교·학원 (open.neis.go.kr)



한국은행 ECOS

기준금리·CD금리·CPI·M2

## 시간 범위의 의의

2019-2025년은 **COVID-19 팬데믹**  
· **금리 인상** · **인하 전환**의 **3대 거시 국**  
**면**을 모두 포함하여, 시장 국면별 설명  
패턴 안정성 검증에 적합.

# 02

## 이론적 배경 및 선행연구

1. 헤도닉 가격모형과 정규화
2. 머신러닝 기반 예측
3. XAI와 SHAP
4. 선행연구 종합

# 헤도닉 가격모형과 본 연구의 설계

## 기존 헤도닉 OLS

$$P = \beta_0 + \beta_1 z_1 + \dots + \beta_n z_n + \varepsilon$$

- Lancaster(1966) · Rosen(1974)
- 총가격을 종속변수로 사용

### 3대 한계

- 선형 가정 → 비선형 미포착
- 상호작용 수동 지정 필요
- 다중공선성 취약 (VIF 110+)



## 본 연구: log(m<sup>2</sup>당 가격)

$$\ln(P/A) = \beta_0 + \sum \beta_i x_i + \varepsilon$$

- Malpezzi(2003), Sirmans et al.(2005)
- 단위면적 정규화 log-price 전통

### 3대 이점

- 규모효과를 분모로 제거
- 이분산성 자연 완화
- 준탄력성  $(e^{\beta} - 1) \cdot 100\%$  해석



# 머신러닝 기반 예측

## Random Forest

Breiman (2001)

배경 기반

독립 트리 앙상블 → 예측값 평균. 분산 감소에 강점.

|                  |     |
|------------------|-----|
| n_estimators     | 200 |
| max_depth        | 15  |
| min_samples_leaf | 5   |

## XGBoost

대표 해석 모형

Chen & Guestrin (2016)

부스팅 + 정규화

이전 트리 잔차를 순차 학습 → 편향 감소에 강점. L1/L2 정규화 내장.

|                    |           |
|--------------------|-----------|
| max_depth          | 8         |
| learning_rate      | 0.1       |
| reg_alpha / lambda | 0.1 / 1.0 |
| 최대 boosting 라운드    | 2,000     |

모든 분할 · 모든 지역 모형에 **동일 하이퍼파라미터**를 적용하여 비교 가능성 확보

# SHAP과 본 연구의 활용

# SHAP

## SHapley Additive exPlanations

Lundberg & Lee (2017) — 게임이론의 Shapley value를 ML 예측값 분해에 적용.  
각 특성이 개별 예측에 미치는 기여를 이론적으로 일관되게 분해.

### 글로벌

#### 변수 중요도 서열

mean(|SHAP\_log|) 기준 18개 변수 서열과 비중(%)

### Dependence

#### 비선형 패턴 검증

변수값 ↔ SHAP 산점도 — U자형, 체감, 임계구간 확인

### Local

#### 개별 거래 분해

Force/Waterfall — base value에서 최종 예측까지 변수별 기여

# 선행연구 비교 및 본 연구의 위치

| 연구                  | 종속변수                          | 공간 단위      | 모형                    | 해석        |
|---------------------|-------------------------------|------------|-----------------------|-----------|
| Čeh et al. (2018)   | 총가격                           | Ljubljana  | OLS vs RF             | 성능만       |
| Chun et al. (2025)  | 총가격                           | 서울 구       | XGB + SHAP            | 통합 SHAP   |
| Kim et al. (2025)   | 총가격                           | 한국         | XAI 앙상블               | 통합 SHAP   |
| Neves et al. (2024) | 총가격                           | 리스본        | XGB + SHAP            | 공원 거리     |
| 본 연구 (2026)         | $\log(\text{m}^2\text{당 가격})$ | 서울 215 행정동 | OLS + RF + XGB + SHAP | 지역 별도 3모형 |

차별화된 기여 — 단위면적 정규화 × 행정동 세분화 × 지역 별도 모형의 3축 결합은  
국내 부동산 XAI 문헌에서 최초 적용

# 03

## 연구 설계 및 방법

1. 연구 흐름 및 변수 설정
2. 3가지 데이터 분할
3. 모형 · 평가 지표 · SHAP
4. 강건성 점검 및 지역 별도 모형

# 연구의 5단계 흐름

01

## 데이터 수집

국토부 · 서울데이터  
NEIS · ECOS

02

## 전처리 · 파생

법정동 → 행정동 매핑  
 $Y = \log(P/A)$  파생

03

## 모형 적합

OLS · RF · XGBoost  
3가지 분할

04

## SHAP 해석

TreeSHAP 5,000 샘플  
글로벌 + Dependence

05

## 강건성 점검

지역 별도 · Ablation  
Moran's I · 시기별

## 종속변수 설계

$$Y = \ln(\text{거래금액[만원]} / \text{전용면적[m}^2\text{]})$$

규모효과를 분모로 제거 → 잔여 질적·입지적 설명 신호 추출.  
헤도닉 문헌의 표준 log-price 전통 연결.

## 독립변수 18개

물리 3 전용면적·층·건물연령

입지 2 강남구분·지하철역수

환경 9 학교·CCTV·백화전·공원·도서관·하원·어린이집

# 3가지 데이터 분할 방식

## ① 무작위

### Random 70/10/20

학습 274,277 / 검증 39,183 / 테스트 78,366

측정 대상: 동일 단지 내 예측 성능

동일 단지 반복거래 공존 가능 → 낙관적 추정

## ② Group

### 단지 기준 분할

법정동 + 아파트명 기준 8,601개 단지, overlap = 0

측정 대상: 미경험 단지 일반화

단지 반복거래 누수 차단 → 가장 보수적

## ③ 시간순

### Chronological

학습 ≤ 2023.12 / 검증 2024.01-06 / 테스트 2024.07 이후

측정 대상: 미래 시점 예측

시장 국면 이동(금리 인하 전환) 반영

이중 기준 해석 — 무작위  $R^2$ 는 "동일 단지 내", Group/시간순  $R^2$ 는 "미경험 단지·미래 시점". 두 기준 병행으로 낙관 편향 완화

# 04

## 실증 분석 결과

1. 기술통계 및 지역 분포
2. 상관관계 · VIF · Ablation
3. Moran's I 공간 자기상관
4. 모형별 · 분할별 성능
5. SHAP 글로벌 + 지역 별도

## 단위면적당 가격의 지역 분포

1,338 만  
원/m<sup>2</sup>

전체 평균

n = 391,826 · 중앙값 1,143

2,208

강남3구 평균

n = 65,077 · 중앙값 2,040

1,165

비강남 22구 평균

n = 326,749 · 중앙값 1,054

1.90×

강남 : 비강남 단위가격 배율

총가격 배율 2.20×보다 작음 → 강남에 대형 평형이 상대적으로 많이 분포하여  
총가격 격차의 일부가 규모효과에서 비롯됨을 단위면적 정규화가 실증.



# 모형별 · 분할별 예측 성능

| 분할             | OLS $R^2$ | RF $R^2$ | XGB $R^2$     | XGB Median APE |
|----------------|-----------|----------|---------------|----------------|
| 무작위 (동일 단지 내)  | 0.5061    | 0.8937   | <b>0.9554</b> | <b>4.16%</b>   |
| Group (미경험 단지) | 0.4618    | 0.7414   | <b>0.8005</b> | 11.72%         |
| 시간순 (미래 시점)    | 0.3939    | 0.6955   | <b>0.7972</b> | 12.61%         |

## 관찰 1

### 일관된 서열

모든 분할에서 **XGB > RF >> OLS** — 비선형 모형의 구조적 우위

## 관찰 2

### Group $\approx$ 시간순

두 분할의  $R^2$  차이 **0.003** — 단지 누수 > 국면 이동 효과

## 관찰 3

### 실무 일반화 기준선

미경험 단지 예측  **$R^2 \approx 0.80$ , Median APE  $\approx 12\%$**

# SHAP Top 6 — 규모 정규화가 가져온 재편

## v6 총가격 모형

|           |       |
|-----------|-------|
| 1. 전용면적   | 22.2% |
| 2. 강남구분   | 16.0% |
| 3. 건물연령   | 11.4% |
| 4. M2 통화량 | 8.3%  |
| 5. 백화점수   | 6.8%  |

면적이 SHAP 상위 독점 → 질적·입지적 신호 가려짐



## v7 단위가격 모형

|            |              |
|------------|--------------|
| 1. 건물연령    | 12.4%        |
| 2. 강남구분    | 11.7%        |
| 3. 어린이집수 ★ | 11.5%        |
| 4. M2 통화량  | 10.8%        |
| 5. 학원수 ★   | 9.6%         |
| 6. 전용면적    | 9.6% (1위→6위) |

주거권 · 사교육 · 재건축 신호 전면화

# 지역 별도 모형 — 질적으로 다른 두 시장



**강남 3구** n = 65,077

**XGB  $R^2 = 0.9356$  · Median APE 4.10%**

| 순위      | 변수    | 비중           |
|---------|-------|--------------|
| 1       | 건물연령  | <b>16.5%</b> |
| 2       | 소비자물가 | 13.3%        |
| 3       | 백화점수  | 13.0%        |
| 4       | 전용면적  | 12.7%        |
| 5       | M2    | 8.5%         |
| 17(최하위) | 어린이집수 | 소수           |

**주도 축:** 재건축 기대 · 상업 집적



**비강남 22구** n = 326,749

**XGB  $R^2 = 0.9421$  · Median APE 4.07%**

| 순위 | 변수    | 비중           |
|----|-------|--------------|
| 1  | 건물연령  | 14.8%        |
| 2  | 소비자물가 | 11.8%        |
| 3  | 전용면적  | 11.2%        |
| 4  | 어린이집수 | <b>10.6%</b> |
| 5  | M2    | 10.1%        |
| 6  | 학원수   | <b>8.6%</b>  |

**주도 축:** 주거권 · 사교육 · 거시 유동성

# 강건성 점검 — Ablation + Moran's I

## Ablation — 프록시 변수 제거

학원수 · 어린이집수 (구 단위 프록시) 제거 시  $R^2$  변화

| 모형            | $\Delta R^2_{\log}$ |
|---------------|---------------------|
| OLS           | -0.0542             |
| Random Forest | -0.0062             |
| XGBoost       | <b>-0.0004</b>      |

→ XGB는 두 프록시 없이도 동등 구조 유지

구 단위 배분의 측정 한계가 전체 결과를 왜곡하지 않음

## Moran's I — 잔차 공간 자기상관

214개 행정동 평균 잔차 · 같은 구 내 인접 가중 · 499회 순열

| 모형      | I             | Z     | p       |
|---------|---------------|-------|---------|
| OLS     | <b>0.3247</b> | 8.882 | < 0.001 |
| XGBoost | 0.0042        | 0.252 | 0.880   |

→ XGB의 비선형 조합이 공간 구조 흡수

공간계량 모형 없이도 공간 이질성 대응

# 05

## 결론 및 시사점

1. 학술 · 정책 · 실무 시사점
2. 연구의 한계 및 향후 과제

# 3층위 시사점

## 학술적

### XAI 국내 적용 확장

단위면적 정규화 + 행정동 세분화 + 지역 별도 모형의  
3축 결합은 국내 부동산 XAI 문헌 최초 적용.

공간 이질성의 질적 구조 직접 실증.

## 정책적

### 이원 시장 설계

강남 = 재건축·상업, 비강남 = 주거권·사교육.

가격 수준만 다른 것이 아닌 **결정 구조 자체가 상이**.

정책 수단의 지역별 차별적 파급효과 시사.

## 실무적

### AVM 설명 책무

단위가격 SHAP 분해 → 면적에 가려지지 않은 질적 프리미엄 투명화.

프롭테크·감정평가 **설명 책무** 지원.

**핵심 메시지** — 서울 아파트 단위가격의 설명 구조는 지역별로 질적으로 다르며, 단위면적 정규화는 규모효과에 가려져 있던 주거권·사교육·재건축 신호를 드러낸다.

# 연구의 한계 및 향후 과제

## ! 현재 한계

- 시설 변수 **stock 병합** — 연도별 변동 미반영 교수 지적
- 학원·어린이집 **프록시** — 구 단위 균등 배분 한계
- 질적 변수 **미반영** — 브랜드·조망·재건축 추진 단계
- **Moran's I** 간이 가중 — 정밀 경계 기반 미적용
- 공간계량(**SAR/SEM**) 직접 비교 미수행
- 강남 표본 규모 — 비강남의 1/5

## 🚀 향후 과제

- 연도별 시설 **패널** — 행안부·교육부 연간 스냅샷
- **GIS** 최근접 거리 — nearest distance 변수
- **Queen/Rook** 가중 — 경계 기반 정밀 공간 행렬
- **ML** 확장 — LightGBM · CatBoost · TabNet
- **XAI** 교차 — LIME · ALE · Permutation Importance
- **범위 확장** — 수도권·지방 대도시로 비교

# 감사합니다

경청해 주셔서 감사드립니다.

질문 · 피드백 환영합니다

박 현 근 · 한양대학교 부동산융합대학원