



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

이학석사 학위논문

SRGCNN 모델을 이용한 서울시 아파트 매매 가격 예측

Prediction of Seoul Apartment Sale Prices Using
Spatial Regression Graph Convolutional Neural Networks

2024 년 2 월

서울대학교 대학원

통계학과

진 수 정

SRGCNN 모델을 이용한
서울시 아파트 매매 가격 예측

Prediction of Seoul Apartment Sale Prices Using
Spatial Regression Graph Convolutional Neural
Networks

지도교수 임 채 영

이 논문을 이학석사 학위논문으로 제출함

2024 년 2 월

서울대학교 대학원

통계학과

진 수 정

진 수 정 의 이학석사 학위논문을 인준함

	2024 년 2 월	
위 원 장	<u>임 요 한</u>	(인)
부위원장	<u>임 채 영</u>	(인)
위 원	<u>박 건 웅</u>	(인)

국문초록

SRGCNN 모델을 이용한 서울시 아파트 매매 가격 예측 Prediction of Seoul Apartment Sale Prices Using Spatial Regression Graph Convolutional Neural Networks

서울시 아파트 매매 가격은 다양한 시공간적 요인에 의해 복잡하게 변동하며, 주요한 요인 중 하나는 지리적 위치이다. 본 연구에서는 Zhu 등(2022)이 제시한 Spatial Regression Graph Convolutional Neural Networks(SRGCNN) 및 그 확장형인 Geographically Weighted SRGCNN(SRGCNN-GW) 모델을 활용하여 지리적 위치에 따른 복잡한 공간적 패턴을 포착하고 서울시 아파트 매매 가격의 예측을 수행한다. SRGCNN은 공간적 연결성을 그래프 형태로 반영하여 복잡한 공간적 상호작용과 관계를 효과적으로 학습한다. 본 연구에서는 아파트의 특성, 아파트가 위치한 지역의 공간적 요인, 그리고 거래된 시점의 시간적 요인을 고려하여 예측을 수행한다. 또한 아파트 매물 간의 공간적 연결성을 모델링하기 위해 다양한 공간 가중치 행렬을 적용하여 적합을 해보고 최적의 공간 가중치 행렬을 탐색한다. 마지막으로 전통적인 공간 데이터 예측 방법인 크리깅과의 성능 비교를 통해 SRGCNN 및 SRGCNN-GW 모델의 유효성을 평가한다.

주요어: 공간통계, SRGCNN, 공간 가중치 행렬, 서울 아파트 매매 가격

학번: 2022-22742

목 차

국문초록	i
목 차	ii
표 목차	iv
그림 목차	v
1 서론	1
1.1 연구 목표	2
2 데이터 설명	3
2.1 데이터 구성	3
2.2 탐색적 데이터 분석	5
3 분석 방법 소개	11
3.1 GCNN	11
3.2 SRGCNN	13
3.3 SRGCNN-GW	15
4 분석 과정	17
4.1 공간 가중치 행렬 적합	17
4.1.1 k-최근접 이웃 공간 가중치 행렬 적합	18

4.1.2	역거리 공간 가중치 행렬 적합	19
4.2	모형 세부사항	19
4.3	비교 모형	20
4.3.1	항등 행렬 기반 SRGCNN	20
4.3.2	일반 크리깅(Universal Kriging)	20
4.4	결과 및 분석	22
4.4.1	인접 행렬에 따른 SRGCNN 모형의 성능 비교	22
4.4.2	SRGCNN-GW, SRGCNN, 일반 크리깅 모형의 성능 비교 .	24
4.4.3	분석 결과	24
5	결론	31
	Abstract	36

표 목차

표 2.1	사용 변수	5
표 4.1	인접 행렬에 따른 SRGCNN 모형의 성능 비교	23
표 4.2	SRGCNN-GW, SRGCNN, 일반 크리깅 모형의 성능 비교	25

그림 목차

그림 2.1	평당 거래금액 히스토그램	6
그림 2.2	로그변환된 평당 거래금액 히스토그램	6
그림 2.3	공간 좌표별 로그 평당 거래금액 분포	7
그림 2.4	2020년 7월 1일자 로그변환된 평당거래금액의 배리오그램 구름	8
그림 2.5	2020년 7월 1일자 로그변환된 평당거래금액의 경험적 배리오 그램	10
그림 3.1	GCNN 모형의 구조	13
그림 4.1	테스트 데이터의 실제 평당거래금액과 SRGCNN-GW(D) 모 형의 예측 결과	25
그림 4.2	SRGCNN-GW(D) 모형의 예측 오차	26
그림 4.3	테스트 데이터의 실제 평당거래금액과 SRGCNN(D) 모형의 예측 결과	27
그림 4.4	SRGCNN(D) 모형의 예측 오차	28
그림 4.5	테스트 데이터의 실제 평당거래금액과 일반 크리깅(Univer- sial Kriging) 모형의 예측 결과	29
그림 4.6	일반 크리깅(Universal Kriging) 모형의 예측 오차	30

제 1 장 서론

서울시는 대한민국의 수도로서 높은 인구 밀도와 복잡한 도시 구조를 지니고 있다. 이러한 도시 구조 속에서 아파트는 주요한 주거 형태로 존재하며, 그 매매 가격은 다양한 시공간적 요인에 따라 영향을 받는다. 이 중 가장 중요한 요인은 지리적 위치로, 아파트의 위치, 주변 환경, 그리고 특히 인접한 다른 아파트와의 상호작용은 가격 결정에 큰 영향을 미친다. 서울시 아파트 매매 가격의 예측은 복합적으로 작용하는 다양한 요인을 고려해야 하는 복잡한 문제이다.

공간 데이터는 공간상의 위치 정보를 포함하고 있는 데이터로, 공간 데이터의 공간적 패턴을 잡아내기 위한 다양한 방법들이 공간통계학에서 연구되었다. 크리깅(Kriging)은 전통적인 공간 데이터 예측 방법 중 하나로, 주어진 관측점들 사이의 공간적 상관관계를 통해 미관측 지점의 값을 예측하는 기법이다. 하지만 크리깅은 데이터의 정규성을 포함한 여러 가정 하에서 예측값을 도출하기 때문에 복잡한 공간적 패턴을 잡아내기에는 한계가 있다.

최근 딥러닝 분야에서 그래프 구조를 활용하여 복잡한 데이터의 상호 관계와 패턴을 학습하는 Graph Convolutional Neural Networks(GCNN)이 주목받기 시작했다. 기존의 합성곱 신경망(CNN)이 고정된 그리드 구조에 있는 데이터만을 처리할 수 있는 반면, GCNN은 그래프 구조를 통해 비구조화된 데이터 간의 관계를 모델링할 수 있다. 이러한 GCNN을 기반으로 Zhu 등(2022)이 제시한 Spatial Regression Graph Convolutional Neural Networks(SRGCNN) 모형은 공간적 연결성을 그래프 형태로 반영하여 복잡한 공간적 상호작용과 관계를 효과적으로 학습한다. SRGCNN은 크리깅과 같은 기존의 전통적인 방법들이 가진 한계를 극복하고, 특히 복잡한 공간적 패턴을 잡아냄으로써 예측 정확도를 향상시키는 것을

목표로 한다. 이는 서울시 아파트 매매 가격 데이터와 같은 복잡한 공간 데이터의 분석에 유용한 모형이다.

1.1 연구 목표

본 연구에서는 SRGCNN 모형을 활용하여 서울시 아파트 매매 가격의 예측을 수행한다. 이 때 아파트가 위치한 지역의 공간적 요인, 그리고 거래된 시점의 시간적 요인을 고려한다. 또한 아파트 매물 간의 공간적 연결성을 모델링하기 위해 다양한 공간 가중치 행렬을 적용하여 적합을 해보고 최적의 공간 가중치 행렬을 찾아 보고자 한다. 마지막으로 크리깅과의 성능 비교를 통해 SRGCNN 모형이 주어진 데이터의 예측에 있어 얼마나 효과적인지 살펴보고자 한다.

제 2 장 데이터 설명

본 연구에서는 서울시 25개 자치구에서 2020년 1월 1일부터 2023년 4월 24일까지 거래된 아파트 매매 데이터를 활용하여 분석을 진행하였다. 그리고 아파트 매매 가격에 영향을 줄 수 있는 공변량으로는 아파트의 평수, 방과 욕실의 수, 층수, 연식 등 아파트의 특성과 아파트로부터 가장 가까운 지하철역까지의 거리, 주변 학군 등 아파트의 위치에 따른 공간적 요인, 그리고 아파트가 거래된 시점의 기준 금리를 고려하였다.

데이터 구축을 위해 국토교통부 실거래가 공개시스템, 네이버 부동산, 서울 열린데이터광장 및 문화 빅데이터 플랫폼 홈페이지로부터 2.1장에 나열된 5개의 데이터를 수집하여 결합하였다. 또한 데이터 결합 과정에서 결측이 일어난 행들을 제외한 총 4834개의 아파트 매물에 대한 정보를 최종적으로 분석에 사용하였다.

2.1 데이터 구성

- 국토교통부 실거래가 공개시스템(<https://rt.molit.go.kr>)

아파트 매매 실거래 데이터는 2020년 1월 1일부터 2023년 4월 24일까지 서울 지역의 아파트 거래 기록을 국토교통부 실거래가 공개시스템에서 수집한 것으로, 몇 가지 전처리를 실시하였다.

우선 아파트의 도로명주소를 구글 Geocoding API를 이용하여 위도와 경도 좌표로 변환하였다. 다음으로 아파트의 전용면적을 기준으로 평수를 계산하였고, 아파트의 건축년도와 거래년도의 차이를 통해 아파트의 연식을 산출하였다. 추가로, 한국기업 평판연구소의 2020년 아파트 브랜드 선호도

조사 결과를 참고하여 상위 10위 브랜드에 속하는 아파트는 1, 그렇지 않은 경우는 0으로 표시하였다. 부동산랭킹 사이트의 2019년 구별 평당가를 자료를 기준으로 평균 평당가가 5천만원 이상인 자치구를 5, 4천만원 이상은 4, 3천만원 이상은 3, 2천만원 이상은 2, 1천만원 이상은 1로 표시하였다. 또한 한국은행의 기준금리를 참고하여 아파트의 거래일자에 따른 기준금리 변수를 추가하였다. 마지막으로 아파트의 거래금액을 평수로 나누어 평당 거래금액(만원)을 도출하였다.

아파트의 평수, 층수, 연식, 선호브랜드 여부, 자치구 레벨, 기준금리는 공변량(X)으로 사용되며, 평당 거래금액은 종속변수(Y)으로 사용된다.

- 네이버 부동산(<https://land.naver.com>)

네이버 부동산 사이트로부터 서울 지역의 아파트 정보를 크롤링하였다. 아파트의 도로명주소와 전용면적을 기준으로 아파트 매매 실거래 데이터와 결합하였으며, 결합되지 않는 행들은 제거하였다.

이를 통해 아파트의 방수, 욕실수, 주차대수, 최고층, 최저층, 현관 구조, 난방 방식, 세대수, 임대세대비율, 용적률, 전용율, 건폐율이 공변량(X)으로 추가되었다.

- 서울시 역사마스터 정보

서울 열린데이터광장(<https://data.seoul.go.kr>)에서 지하철역의 위치 좌표를 취득하였다. 지하철역과 아파트의 위치 좌표를 활용하여 아파트로부터 가장 가까운 지하철역까지의 거리(km)를 산출하였다.

- 서울시 학교 기본정보

서울 열린데이터광장(<https://data.seoul.go.kr>)에서 서울 지역의 초등학교, 중학교, 고등학교 자료를 취득하였다. 자치구별 초등학교, 중학교 개수를 산출한 후, 자치구를 기준으로 아파트 매매 실거래 데이터와 결합하였다.

- 국내여행 소비 역세권지도

문화 빅데이터 플랫폼(<https://www.bigdata-culture.kr>)에서 법정동별 음식점 수, 쇼핑센터 수 자료를 취득한 후, 법정동을 기준으로 아파트 매매 실거래 데이터와 결합하였다.

종속변수		평당 거래금액
설명변수	아파트 특성	평수, 방수, 욕실수, 층수, 주차대수, 연식, 선호 브랜드 여부, 최고층, 최저층, 현관 구조, 난방 방식, 세대수, 임대세대비율, 용적률, 전용율, 건폐율
	공간적 특성	지하철역 거리, 음식점 수, 쇼핑센터 수, 초등학교 수, 중학교 수, 자치구 레벨
	시간적 특성	기준금리

표 2.1: 사용 변수

2.2 탐색적 데이터 분석

그림 2.1은 평당 거래금액에 대한 히스토그램으로, 오른쪽으로 꼬리가 긴 분포의 형태를 띄고 있다. 본 연구에서 비교 모형으로 사용한 크리깅은 데이터의 정규성을 가정하고 있으므로, 로그변환을 하여 분석을 진행할 필요가 있다. 따라서 일관적인 성능 비교를 위해 로그변환한 평당 거래금액에 대한 예측을 수행하였다. 그림 2.2는 로그변환한 평당 거래금액에 대한 히스토그램이다.




그림 2.1: 평당 거래금액 히스토그램




그림 2.2: 로그변환된 평당 거래금액 히스토그램

그림 2.3은 공간 좌표별로 로그변환된 평당거래금액의 분포를 나타낸 그림이다. 평당 거래금액의 평균은 약 4200만원이며, 최솟값은 약 750만원(도봉구 쌍문동 소재), 최댓값은 약 1억 4570만원(송파구 잠실동 소재)으로 나타났다. 특히 평당 거래금액은 용산구, 서초구, 강남구에서 높게 관측되었고, 도봉구 지역에서는 상대적으로 낮은 값을 보였다. 이러한 분포를 고려할 때 평당 거래금액에 공간적 의존성이 있음을 확인할 수 있으며, 공간적 의존성을 모형에 반영할 경우 예측 성능의 향상이 기대된다.




그림 2.3: 공간 좌표별 로그 평당 거래금액 분포

N 개의 공간 좌표에서 관측된 데이터 $(y(s_1), y(s_2), \dots, y(s_N))$ 가 있다고 할 때, 배리오그램 구름(Variogram cloud)과 경험적 배리오그램(Empirical variogram)을 통해 공간적 패턴을 세부적으로 파악할 수 있다. 그림 2.4와 그림 2.5는 각각 2020년 7월 1일자 로그변환된 평당거래금액에 대한 배리오그램 구름과 경험적 배

리오그램을 나타낸 그림이다.

배리오그램 구름(Chauvet, 1982)은 모든 가능한 두 공간 좌표쌍 (s_i, s_j) 에 대해 거리 $h = |s_i - s_j|$ 에 따라 다음과 같은 $\gamma^*(h)$ 를 계산하여 개별적인 점으로 나타낸 것이다.

$$\gamma^*(h) = \frac{(y(s_i) - y(s_j))^2}{2}$$

따라서 그림 2.4의 배리오그램 구름을 통해 아파트 거래금액 데이터의 복잡한 구조와 이상치를 파악할 수 있다.




그림 2.4: 2020년 7월 1일자 로그변환된 평당거래금액의 배리오그램 구름

한편, MoM 추정에 기반한 경험적 배리오그램(Matheron, 1963)은 거리 $h = |s_i - s_j|$ 별로 평균화된 $\hat{\gamma}(h)$ 를 나타내며, 이는 다음과 같이 정의된다.

$$\hat{\gamma}(h) = \frac{1}{2|N(h)|} \sum_{(s_i, s_j) \in N(h)} (y(s_i) - y(s_j))^2$$

여기서 $N(h)$ 는 거리가 h 인 모든 공간 좌표쌍 (s_i, s_j) 들의 집합이며, $|N(h)|$ 는 해당 집합의 원소의 수를 의미한다. 그림 2.5의 경험적 배리오그램은 아파트 거래 금액 데이터의 보다 일반적인 공간적 패턴을 이해하고, 데이터에 적합한 모델링 기법을 선택하는 데에 중요한 통찰을 제공한다.

본 연구에서 비교 모형으로 사용한 일반 크리깅(Universal Kriging) 모형 적합 시, 아파트 매물 간의 상대적인 거리를 고려하여 아파트 매매 가격의 공간적 변동성을 포착하기 위해 다음과 같은 구 모형 배리오그램(spherical variogram)을 사용하였다.

$$\gamma(h) = \begin{cases} 0 & \text{for } h = 0 \\ c_0 + c_1 \left\{ \frac{3}{2} \left(\frac{|h|}{R} \right) - \frac{1}{2} \left(\frac{|h|}{R} \right)^3 \right\} & \text{for } 0 < |h| \leq R \\ c_0 + c_1 & \text{for } |h| > R \end{cases}$$

이때 c_0, c_1, R 은 모두 양수이다.




그림 2.5: 2020년 7월 1일자 로그변환된 평당거래금액의 경험적 배리오그램

제 3 장 분석 방법 소개

본 연구에서는 그래프 구조를 바탕으로 한 심층 학습 모형인 SRGCNN과 SRGCNN-GW를 활용하여 서울시 아파트 매매 가격을 예측하였다. 3.1장에서는 Defferrard 등(2016)이 제안한 기본적인 GCNN(Graph Convolutional Neural Networks) 모형에 대해서 소개한다. 다음으로 3.2장에서는 공간적 의존성을 반영한 SRGCNN 모형에 대해 알아보려고 한다. 3.3장에서는 SRGCNN 모형에 공간적 이질성을 추가하여 확장한 모형인 SRGCNN-GW 모형을 알아보려고 한다.

3.1 GCNN

Defferrard 등(2016)이 제안한 GCNN(Graph Convolutional Neural Networks)은 그래프 구조의 데이터를 처리하기 위한 딥러닝 기법 중 하나로, 구조적인 정보와 노드의 특성을 함께 고려하여 그래프 구조의 데이터를 효과적으로 학습할 수 있다.

총 M 개의 관측 데이터가 존재하고 N 개의 공간 좌표가 존재한다고 하자. 각 공간 좌표에는 m_n 개의 관측 데이터가 존재한다. 먼저 그래프 구조는 $G = (V, E)$ 로 표현되는데, 여기서 V 는 노드의 집합, E 는 간선의 집합이다. $\mathbf{W} \in \mathbb{R}^{M \times M}$ 는 인접 행렬로, $w_{ij} \in W$ 는 노드 v_i 와 v_j 가 간선 e_{ij} 로 연결되어 있을 때, 간선의 가중치를 나타낸다. 이 때 노드는 각 아파트 매물을, 간선은 두 아파트 매물 간의 관계를 나타낸다. 다음으로 아파트 매물의 특성은 $(\mathbf{X}, \mathbf{y})$ 로 표현되는데, 여기서 $\mathbf{X} \in \mathbb{R}^{M \times K}$ 는 아파트 매물의 특성 벡터를, $\mathbf{y} \in \mathbb{R}^{M \times 1}$ 는 아파트 매물의 평당 거래 금액을 나타낸다. 이를 식으로 나타내면 다음과 같다.

$$\mathbf{y} = f_{\Theta}(\mathbf{y}, \mathbf{W}, \mathbf{X}) + \epsilon$$

$$m_1 + m_2 + \dots + m_N = M$$

여기서 Θ 는 추정하고자 하는 파라미터이며, ϵ 은 GCNN 모형의 오차이다. 모형은 관측 데이터에 적합될 때 공간적 효과 및 비공간적 효과를 포함한 파라미터 Θ 를 추정한다. GCNN은 그래프 합성곱(Graph Convolution) 연산을 통해 각 아파트 매물의 특성을 인접한 아파트 매물의 특성과 결합한다. 그래프 합성곱 연산은 다음과 같이 표현된다.

$$\mathbf{X}^{l+1} = \sigma(\mathbf{W}\mathbf{X}^l\Theta^l)$$

여기서 $\mathbf{X}^l$ 은 현재 아파트 매물의 특성 벡터, $\mathbf{X}^{l+1}$ 은 업데이트된 아파트 매물의 특성 벡터를 나타내며, σ 는 활성화 함수(activation function)이다. GCNN은 그래프 합성곱 연산을 반복적으로 수행함으로써, 그래프의 전체 구조와 각 노드의 특성을 학습하게 된다. 은닉층(hidden layer) 개수가 2개인 GCNN 모형은 다음과 같이 표현된다.

$$\hat{\mathbf{y}} = \mathbf{W}(\sigma(\mathbf{W}(\sigma(\mathbf{W}\mathbf{X}\Theta^{(1)}))\Theta^{(2)}))\Theta^{(3)}$$

그림 3.1은 GCNN 모형의 구조를 나타낸 그림이다.




그림 3.1: GCNN 모형의 구조

따라서 GCNN 모형으로 다양한 데이터를 효과적으로 학습하기 위해서는 데이터의 구조를 반영하도록 인접 행렬을 적절하게 설정하는 것이 중요하다. GCNN 모형을 한 단계 더 발전시킨 SRGCNN 모형은 공간 가중치 행렬의 활용을 통한 인접 행렬 구성을 제안한다.

3.2 SRGCNN

아파트 매매 데이터를 비롯한 공간 데이터에서 특정 아파트의 매매 가격은 인접한 아파트의 매매 가격에 크게 영향을 받을 수 있으므로, 이러한 공간적 의존성을 반영하는 것이 중요하다. Zhu 등(2022)이 제안한 SRGCNN(Spatial Regression Graph Convolutional Neural Networks) 모형은 GCNN 모형의 발전된 형태로, 공간적 의존성을 활용하여 그래프 구조의 데이터를 처리하는 심층 학습 모델이다.

SRGCNN 모형은 아파트 매물의 공간 좌표를 기반으로 산출한 공간 가중치 행렬(spatial weights matrix)을 인접 행렬로 GCNN 모형에 도입함으로써 공간적 의존성을 반영할 수 있도록 설계되었다. 이러한 공간 가중치 행렬은 특정 데이터에 대해 주변의 데이터가 미치는 영향의 크기와 방향을 나타내는 것으로, 공간 데이터 분석에서 핵심적인 요소이다. 다음은 흔히 사용되는 공간 가중치 행렬 몇 가지를

나타낸 것이다.

1. k-최근접 이웃 공간 가중치 행렬(k-Nearest neighbors weights)

$$w_{ij} = \begin{cases} 1 & \text{if unit } j \text{ is one of the } k \text{ nearest units to that of } i \\ 0 & \text{otherwise} \end{cases}$$

2. 거리 대역 공간 가중치 행렬(Distance band weights)

$$w_{ij} = \begin{cases} 1 & \text{if } 0 \leq d_{ij} \leq d \\ 0 & \text{if } d_{ij} > d \end{cases} \quad \text{for threshold distance } d$$

3. 역거리 공간 가중치행렬(Inverse distance weights)

$$w_{ij} = \begin{cases} \frac{1}{d_{ij}} & \text{if } i \neq j \\ 0 & \text{if } i = j \end{cases}$$

4. 음의 지수 공간 가중치 행렬(Negative exponential weights)

$$w_{ij} = e^{-\alpha d_{ij}} \quad \text{for } \alpha > 0$$

추가적으로, 각 노드는 주변 노드의 정보뿐만 아니라 자기 자신의 정보도 함께 고려해야한다. 이를 위해 대각행렬의 형태로 자기 자신에 대한 가중치를 주는 항을 더해줌으로써 자기 자신의 정보를 보존하도록 한다.

$$\tilde{\mathbf{W}} = \mathbf{W} + c \cdot \mathbf{I}$$

여기서 c 는 양수이며, I 는 항등 행렬(identity matrix)이다. 또한 가중치 행렬 W 과 X^l 를 곱할 때 가중치 행렬이 정규화되어 있지 않으면 X^{l+1} 의 크기가 불안정하게 변할 수 있다. 따라서 X^{l+1} 의 크기가 안정적으로 유지되면서 모델의 학습이 안정적으로 이루어지도록 가중치 행렬을 다음과 같이 정규화하는 과정이 필요하다.

$$\mathbf{W}_L = \tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{W}} \tilde{\mathbf{D}}^{-1/2}$$

$\mathbf{W}_L$ 은 재정규화 라플라스 행렬(renormalized Laplacian matrix)에 해당한다. 여기서 $\tilde{\mathbf{D}}_{ii} = \sum_j \tilde{\mathbf{W}}_{ij}$ 는 차수 행렬(degree matrix)이다. 이와 관련하여 4장에서 k-최근접 이웃 공간 가중치 행렬(k-Nearest neighbor weights)과 역거리 공간 가중치 행렬(Inverse distance weights)을 서울시 아파트 매매 가격 데이터에 적합해보도록 한다.

3.3 SRGCNN-GW

그림 2.3에서 강남 지역의 평당 거래금액은 다른 지역의 평당 거래금액과는 다른 분포를 보였다. 이처럼 공간에 따라 다양한 경향 또는 분산이 존재하여, 서로 다른 지역에서 관측된 데이터가 다른 분포를 가지는 특성을 공간적 이질성이라 한다. 공간 데이터 분석에 있어서 공간적 의존성뿐만 아니라 공간적 이질성도 중요한 요소로 작용한다. Zhu 등(2022)이 제안한 SRGCNN-GW(Geographically Weighted Spatial Regression Graph Convolutional Neural Networks) 모형은

SRGCNN 모델을 확장하여 공간적 이질성을 반영한 모델인데, 이와 같이 공간적 이질성을 고려하여 데이터를 분석하면 더욱 타당한 분석 결과를 얻을 수 있다.

SRGCNN-GW 모델은 SRGCNN의 그래프 합성곱 연산을 확장시킨 개념인 지리적으로 가중된 그래프 합성곱 연산을 수행한다. 지리적으로 가중된 그래프 합성곱 연산은 다음과 같이 표현된다.

$$\mathbf{X}^{l+1} = \sigma(\mathbf{W}(\mathbf{X}^l \otimes \boldsymbol{\Theta}_{local}^l) \boldsymbol{\Theta}^l)$$

여기서 $\boldsymbol{\Theta}_{local}^l$ 는 지리적으로 가중된 매개변수를 포함하고 있으며, $\otimes$ 는 요소 별 곱(element-wise product)을 나타낸다. 은닉층(hidden layer) 개수가 2개인 SRGCNN-GW 모델은 다음과 같이 표현된다.

$$\hat{\mathbf{y}} = \mathbf{W}_L(\sigma(\mathbf{W}_L(\sigma(\mathbf{W}_L(\mathbf{X}^{(1)} \otimes \boldsymbol{\Theta}_{local}^{(1)}) \boldsymbol{\Theta}^{(1)}) \otimes \boldsymbol{\Theta}_{local}^{(2)}) \boldsymbol{\Theta}^{(2)}) \otimes \boldsymbol{\Theta}_{local}^{(3)}) \boldsymbol{\Theta}^{(3)})$$

제 4 장 분석 과정

3장에서 소개한 SRGCNN 및 SRGCNN-GW 모델을 서울시 아파트 매매 데이터에 적용하여 평당 거래금액의 예측을 수행한다. 이 때 각 모형별로 k-최근접 이웃 공간 가중치 행렬과 역거리 공간 가중치 행렬을 적합한다. 추가적으로 항등 행렬을 인접 행렬로 사용한 GCNN 모형을 이용함으로써 공간적 의존성을 고려하지 않았을 때의 성능을 파악하고자 한다. 또한 Christensen 등(2001)에 의해 제시된 일반 크리깅(Universal Kriging) 모형을 데이터에 적용하여 SRGCNN 및 SRGCNN-GW 모형과의 성능을 비교하고자 한다. 이 때 각 모형(SRGCNN, SRGCNN-GW, 일반 크리깅)을 데이터에 적용하기에 앞서 데이터의 모든 설명변수에 대해 최대-최소 정규화(min-max scaling)를 진행해주었다.

4.1 공간 가중치 행렬 적합

본 연구에서는 모든 아파트 매물에 대해 공간 가중치 행렬을 산출하였다. 이 때 아파트의 특성상 하나의 공간 좌표에 대응되는 아파트 매물의 개수는 여러 개일 수 있다. 안정적으로 공간 가중치 행렬을 산출하기 위해 유일한 공간 좌표에 대해 공간 가중치 행렬을 생성한 후, 이를 각각의 아파트 매물에 대한 공간 가중치 행렬로 확장하였다.

$$\mathbf{W}_{loc} = \begin{bmatrix} w_{11} & \cdots & w_{1N} \\ \vdots & \ddots & \vdots \\ w_{N1} & \cdots & w_{NN} \end{bmatrix} \in \mathbb{R}^{N \times N}$$

$\mathbf{W}_{loc}$ 는 유일한 공간 좌표에 대한 공간 가중치 행렬이다.

$$\mathbf{W} = \begin{bmatrix} w_{11} \cdot \mathbf{J}_{m_1, m_1} & \cdots & w_{1N} \cdot \mathbf{J}_{m_1, m_N} \\ \vdots & \ddots & \vdots \\ w_{N1} \cdot \mathbf{J}_{m_N, m_1} & \cdots & w_{NN} \cdot \mathbf{J}_{m_N, m_N} \end{bmatrix} \in \mathbb{R}^{M \times M}$$

$\mathbf{W}_{loc}$ 를 확장한 $\mathbf{W}$ 는 모든 아파트 매물에 대한 공간 가중치 행렬이다. 여기서 $\mathbf{J}_{m_i, m_j}$ 은 행렬의 모든 원소가 1로 이루어진 $m_i \times m_j$ 크기의 행렬을 의미한다. 이제 아파트의 유일한 공간 좌표로부터 $\mathbf{W}_{loc}$ 를 산출한 과정을 살펴보고자 한다.

4.1.1 k-최근접 이웃 공간 가중치 행렬 적합

k-최근접 이웃 공간 가중치 행렬을 구축하기 위해 $k = 5$ 를 설정하고, 각 공간 좌표별로 가장 거리가 가까운 5개의 공간 좌표에 가중치 1을 부여하였다. 이 때 공간 가중치 행렬의 대각 원소에 대해 가중치 1을 부여함으로써 자기 자신의 공간 좌표에 대한 가중치를 추가하였다. 또한 공간 가중치 행렬의 i 행 j 열의 원소나 j 행 i 열의 원소가 가중치 1을 가지면, $\mathbf{W}_{loc}$ 의 j 열의 원소와 j 행 i 열의 원소 모두에 대해 가중치 1을 부여함으로써 $\mathbf{W}_{loc}$ 가 대칭 행렬(symmetric matrix)이 되도록

구성한다.

4.1.2 역거리 공간 가중치 행렬 적합

역거리 공간 가중치 행렬을 구축하기 위해 각 공간 좌표에서 다른 공간 좌표까지의 거리를 계산하였다. 이 거리는 각 좌표 쌍 $(lat_1, long_1)$, $(lat_2, long_2)$ 에 대해 지구 표면상의 최단 경로로 산출하였으며, 이를 위해 다음의 하버사인 공식(Haversine formula)를 활용하였다.

$$h = 2r \arcsin \sqrt{\sin^2 \left(\frac{\Delta lat}{2} \right) + \cos(lat_1) \cos(lat_2) \sin^2 \frac{\Delta long}{2}}$$

여기서 r 은 지구의 반지름이며, Δlat 과 $\Delta long$ 은 각각 라디안 단위로 산출된 두 공간 좌표의 위도와 경도의 차이를 의미한다. 계산된 거리의 역수를 공간 가중치 행렬의 가중치로 사용함으로써, 가까운 공간 좌표들이 더 큰 영향을 미치도록 설정하였다. 또한 공간 가중치 행렬의 대각 원소에 대해 가중치의 최댓값을 부여함으로써 자기 자신의 공간 좌표에 대한 가중치를 추가하였다.

4.2 모형 세부사항

SRGCNN-GW 모형과 SRGCNN 모형을 구축하기에 앞서 모형의 세부사항을 결정하는 과정을 거쳤다. 모형의 은닉층(hidden layer) 수, 드롭아웃(dropout) 비율, 학습률(learning rate), 에폭(epoch) 수는 하이퍼파라미터(hyperparameter) 튜닝 과정을 통해 최적화되었다. 먼저, SRGCNN-GW 모형에 대해서는 은닉층을 3개로 설정하고, 학습률은 5×10^{-2} 로, 에폭 수는 10,000으로, 그리고 드롭아웃

비율은 0으로 선정하였다. SRGCNN 모형에 대해서는 은닉층을 2개로 설정하고, 학습률은 3×10^{-1} 로, 에폭 수는 10,000으로, 그리고 드롭아웃 비율은 0.2로 선정하였다.

4.3 비교 모형

본 연구에서는 공간적 의존성을 반영하지 않은 일반적인 딥러닝 모형과, 공간 통계에서 자주 활용되는 일반 크리깅 모형을 비교모형으로 선정하였다. 이를 통해 SRGCNN 및 SRGCNN-GW 모형의 성능을 폭넓게 평가하고자 한다.

4.3.1 항등 행렬 기반 SRGCNN

공간적 의존성을 반영하지 않기 위해 항등 행렬을 인접 행렬로 사용한 SRGCNN 모형인 SRGCNN(I)을 구축하였다. k-최근접 이웃 공간 가중치 행렬 및 역거리 공간 가중치 행렬을 인접 행렬로 사용한 SRGCNN 모형과의 비교를 통해 공간적 의존성이 모형의 예측 성능에 미치는 영향을 분석할 수 있다.

4.3.2 일반 크리깅(Universal Kriging)

일반 크리깅(Stein et al., 2001)은 데이터의 공간적 패턴을 모델링하기 위해 널리 사용되는 기법 중 하나이다. 이 방법은 아래와 같은 공간 확률 과정을 고려한다.

$$y(s) = x^T(s)\beta + \epsilon(s)$$

$$x(s) = (x_1(s), \dots, x_{23}(s))^T, \beta = (\beta_1, \dots, \beta_{23})^T$$

주어진 훈련 데이터 $Y = (y(s_1), \dots, y(s_n))^T$ 를 바탕으로, 테스트 데이터의 특정 공간 좌표 s_0 에서의 $y(s_0)$ 을 예측하는 것이 목표이다. 이때 $y_0 = y(s_0)$, $x_0 = x(s_0)$, $\text{cov}(Y) = \Sigma$, $\text{cov}(y(s_j), y_0) = \delta_j$ ($j = 1, \dots, n$)라 하자. 일반 크리깅에서는 y_0 를 라그랑주 승수법을 사용하여 아래와 같이 예측할 수 있다.

$$\hat{y}_0 = x_0^T \hat{\beta} + \delta^T \Sigma^{-1} (y - X \hat{\beta})$$

$$\delta = (\delta_1, \dots, \delta_n)^T$$

여기서 β 는 일반화된 최소 제곱(GLS) 방식으로 추정된 $\hat{\beta} = (X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} Y$ 를 사용한다. 또한 2.2장에서 언급한 구형 배리오그램(spherical variogram) 모형을 가정하고 이를 기반으로 Σ 와 δ 를 추정하였다. 모형에 대한 모수의 추정 방식으로는 Approximated Weighted Least Square(AWLS) 방법(Cressie, 1985)를 사용하였으며, 구형 배리오그램의 모수 $\theta = (c_0, c_1, R)$ 에 대해 아래와 같이 $\hat{\theta}_{AWLS}$ 를 구하였다.

$$\hat{\theta}_{AWLS} = \underset{\theta}{\operatorname{argmin}} \sum_j \frac{|N(h_j)|}{\gamma^2(h_j; \theta)} (\hat{\gamma}(h_j) - \gamma(h_j; \theta))^2$$

4.4 결과 및 분석

전체 데이터에 대해 25%, 50%, 75%의 훈련 데이터 비율(training ratio)로 랜덤 추출을 진행하여, 추출된 훈련 데이터로 SRGCNN-GW, SRGCNN, 일반 크리깅 모형을 학습하고 추출되지 않은 테스트 데이터로 각 모형에 대한 성능을 평가하였다. 이 때 각 모형과 훈련데이터 비율에 대해 같은 작업을 30번씩 반복 수행하였으며, 성능을 평가하기 위한 지표로는 평균절대오차(Mean Absolute Error, MAE)를 사용하였다. 테스트 데이터의 종속변수를 $\{y_1, y_2, \dots, y_{M_{ratio}}\}$, 그 예측값을 $\{\hat{y}_1, \hat{y}_2, \dots, \hat{y}_{M_{ratio}}\}$ 라 할 때, MAE는 다음과 같이 표현된다. 이때 각 y_i $\hat{y}_i$ 에 대해 지수 함수를 적용하여 로그변환된 평당 거래금액을 원래 스케일로 되돌리는 작업을 진행하였다.

$$MAE = \frac{1}{M_{ratio}} \sum_{i=1}^{M_{ratio}} |e^{y_i} - e^{\hat{y}_i}|$$
$$M_{ratio} = M \cdot ratio, \quad ratio = 0.25, 0.5, 0.75$$

4.4.1 인접 행렬에 따른 SRGCNN 모형의 성능 비교

표 4.1은 인접 행렬에 따른 SRGCNN 모형의 성능을 비교한 결과이다. 여기서 D 는 역거리 공간 가중치 행렬을, N 은 k-최근접 이웃 공간 가중치 행렬을, 그리고 I 는 항등 행렬을 의미한다.

역거리 공간 가중치 행렬(D) 및 k-최근접 이웃 공간 가중치 행렬(N)을 사용한 SRGCNN 모형은 훈련 데이터의 비율이 증가함에 따라 MAE값이 감소하는 경향을 보였다. 이는 공간적 의존성을 반영하는 모형은 훈련 데이터의 양이 늘어

날수록 공간적 특성을 보다 효과적으로 학습하고 예측 성능을 개선함을 시사한다. 반면, 항등 행렬(I)을 사용한 SRGCNN 모형은 훈련 데이터의 비율과는 상관없이 일정한 MAE값을 보여주었다. 이는 공간적 의존성을 고려하지 않은 경우, 훈련 데이터의 양이 예측 정확도에 미치는 영향이 제한적임을 나타낸다.

전반적으로 역거리 공간 가중치 행렬(D)를 사용한 SRGCNN 모형이 가장 작은 MAE값을 나타내며 가장 우수한 성능을 보였다. 반면 k -최근접 이웃 공간 가중치 행렬(N)을 사용한 SRGCNN 모형의 경우, 항등 행렬(I)을 사용한 SRGCNN 모형에 비해 더 높은 MAE값을 보였다. 이는 k -최근접 이웃 방식이 일정 수준 공간적 의존성을 반영하지만, 거리에 기반한 역거리 방식만큼 효과적이지 않음을 시사한다.

이를 통해 공간 데이터 분석에서는 공간적 의존성을 적절히 반영하는 모형의 선택이 중요하다는 것을 확인할 수 있다. 또한 역거리 공간 가중치 행렬이 서울시 아파트 매매 가격 데이터에 있어 효과적임을 관찰하였다.

		25% training ratio	50% training ratio	75% training ratio
		MAE	MAE	MAE
SRGCNN(D)	Mean	806.489	791.383	781.747
	SD	13.498	11.241	15.753
SRGCNN(N)	Mean	896.978	878.495	872.888
	SD	18.589	16.335	21.718
SRGCNN(I)	Mean	849.315	843.359	846.164
	SD	15.558	13.837	25.615

표 4.1: 인접 행렬에 따른 SRGCNN 모형의 성능 비교

4.4.2 SRGCNN-GW, SRGCNN, 일반 크리깅 모형의 성능 비교

표 4.2는 역거리 공간 가중치 행렬(D)을 사용한 SRGCNN 및 SRGCNN-GW 모형과 일반 크리깅 모형의 성능을 비교한 결과이다.

분석 결과, SRGCNN-GW 모형이 모든 훈련 데이터 비율에서 가장 작은 MAE 값을 나타내며 우수한 성능을 보였다. 특히, 훈련 데이터 비율이 증가함에 따라 SRGCNN-GW 모형의 성능 향상이 두드러지게 나타났으며, 이는 해당 모형이 공간적 의존성과 이질성을 모두 효과적으로 포착하여 아파트 매매 가격을 높은 정확도로 예측하고 있음을 나타낸다.

한편 SRGCNN 모형은 전반적으로 일반 크리깅 모형과 유사한 성능을 보이는 것으로 나타났다. 이는 공간적 의존성만을 고려한 SRGCNN 모형이 공간적 이질성을 포착하는 데는 상대적으로 한계가 있음을 시사한다.

이러한 결과들은 서울시 아파트 매매 가격 예측에 있어서 공간적 의존성과 이질성을 모두 고려하는 SRGCNN-GW 모형이 다른 모형들에 비해 보다 정확하고 신뢰할 수 있는 예측을 제공함을 보여준다.

4.4.3 분석 결과

SRGCNN-GW(D)

그림 4.2은 25% 비율로 추출된 테스트 데이터에 대한 실제 평당거래금액과 SRGCNN-GW(D) 모형으로 예측된 결과를 나타낸 그림이다. 이를 통해 실제값과 예측값이 전반적으로 유사하게 분포하고 있음을 확인할 수 있다. 그림 4.2를 통해 예측값과 실제값 사이의 차이인 예측 오차를 보다 세부적으로 분석하고자 한다.

		25% training ratio	50% training ratio	75% training ratio
		MAE	MAE	MAE
SRGCNN -GW(D)	Mean	716.325	644.662	594.007
	SD	18.007	14.093	18.267
SRGCNN(D)	Mean	806.489	791.383	781.747
	SD	13.498	11.241	15.753
Universal Kriging	Mean	814.813	792.459	762.431
	SD	56.723	39.116	30.173

표 4.2: SRGCNN-GW, SRGCNN, 일반 크리깅 모형의 성능 비교




그림 4.1: 테스트 데이터의 실제 평당거래금액과 SRGCNN-GW(D) 모형의 예측 결과

그림 4.3를 통해 SRGCNN-GW(D) 모형이 위도 37.49, 경도 127.04에 위치해 있는 한 아파트에 대해 평당거래금액을 과대추정하고 있음을 알 수 있다. 해당 아파트는 강남구에 위치한 총 16세대로 구성된 소규모 아파트로, 강남구 소재의 대부분의 아파트 매물들과는 다른 특성을 보인다. 이러한 결과는 해당 모형이 자치구 내에서 지역별로 나타나는 특성의 차이를 충분히 반영하지 못했음을 시사한다. 특

히 대다수 지역과는 달리 특정 소수 지역에서 나타나는 고유한 특성까지는 모형이 세밀하게 파악하지 못하는 것으로 보인다.




그림 4.2: SRGCNN-GW(D) 모형의 예측 오차

SRGCNN(D)

그림 4.4는 25% 비율로 추출된 테스트 데이터에 대한 실제 평당거래금액과 SRGCNN(D) 모형으로 예측된 결과이며, 그림 4.5는 예측값과 실제값 사이의 차이인 예측 오차를 나타낸 그림이다.




그림 4.3: 테스트 데이터의 실제 평당거래금액과 SRGCNN(D) 모형의 예측 결과

그림 4.5를 통해 SRGCNN(D) 모형이 서초구 일대에 위치해 있는 아파트에 대해 평당거래금액을 과소추정하고 있음을 알 수 있다. SRGCNN-GW(D) 모형과 비교했을 때, SRGCNN(D) 모형은 더 많은 관측치에 대해 높은 오차를 나타내는 경향을 보인다.




그림 4.4: SRGCNN(D) 모형의 예측 오차

일반 크리깅(Universal Kriging)

그림 4.6은 25% 비율로 추출된 테스트 데이터에 대한 실제 평당거래금액과 일반 크리깅(Universal Kriging) 모형으로 예측된 결과이며, 그림 4.7은 예측값과 실제값 사이의 차이인 예측 오차를 나타낸 그림이다.




그림 4.5: 테스트 데이터의 실제 평당거래금액과 일반 크리깅(Universal Kriging) 모형의 예측 결과

그림 4.7를 통해 일반 크리깅(Universal Kriging) 모형이 특정 지역의 아파트(위도 37.53, 경도 126.95에 위치한 용산구 소재 아파트와 위도 37.60, 경도 127.01에 위치한 성북구 소재 아파트)에 대해 평당거래금액을 과대추정하고 있음을 알 수 있다. 데이터를 보다 면밀히 살펴본 결과, 해당 용산구 소재 아파트 매물은 동일한 단지 내에서 거래되었던 비슷한 조건의 다른 매물들에 비해 확연히 낮은 가격에서 거래되었으며, 성북구 소재 아파트는 총 45세대로 구성된 소규모 아파트로 확인되었다. 또한 시각화 결과를 통해 일반 크리깅 모형이 SRGCNN-GW 모형이나 SRGCNN 모형에 비해 전반적으로 높은 예측 오차를 갖고 있음을 알 수 있다. 이러한 결과는 일반 크리깅 모형이 특정 지역에서 나타나는 독특한 특성을 충분히 반영하지 못한 것으로 해석될 수 있다.




그림 4.6: 일반 크리깅(Universal Kriging) 모형의 예측 오차

제 5 장 결론

본 연구에서는 서울시 아파트 매매 가격 예측을 위해 Zhu 등(2022)이 제시한 Spatial Regression Graph Convolutional Neural Networks(SRGCNN) 및 그 확장 버전인 Geographically Weighted SRGCNN(SRGCNN-GW) 모형을 활용하였다. 이들 모형은 공간적 연결성을 그래프 형태로 반영하여 복잡한 공간적 상호작용을 효율적으로 학습하고, 이를 바탕으로 아파트 매매 가격을 예측하는 데 중점을 두었다.

2장에서는 본 연구에서 사용한 데이터에 대해 소개하였고 배리오그램(Variogram)을 통해 아파트 매매 가격의 공간적 의존성에 대해 탐색하였다. 3장에서는 SRGCNN 및 SRGCNN-GW 모형의 구조와 수식, 그리고 본 연구에서 사용한 공간 가중치 행렬(spatial weights matrix)에 대해 설명하였다. 마지막으로 4장에서는 모형의 예측 성능에 대해 살펴보았다. 4834개의 데이터에 대해 25%, 50%, 75% 비율로 훈련 데이터를 랜덤하게 추출하여 나머지 테스트 데이터를 예측한 결과, 공간적 의존성을 반영한 SRGCNN 모형은 서울시 아파트 매매 가격 예측에 효과적임이 입증되었다. 특히 역거리 공간 가중치 행렬(Inverse distance weights)이 서울시 아파트 매매 가격 데이터의 공간적 패턴을 잘 적합함을 확인하였다. 또한 공간적 이질성을 추가적으로 고려한 SRGCNN-GW 모형은 더욱 높은 예측 정확도를 보였다. 이는 서울시 아파트 가격 예측에 있어서 공간적 의존성뿐만 아니라 공간적 이질성 역시 중요한 요소임을 시사한다.

향후 연구 방향으로서는 자치구 내에서 일부 소수 지역별로 나타나는 세밀한 특성의 차이를 모형에 추가적으로 반영함으로써 이상치에 해당하는 데이터도 잘 예측할 수 있을 것이라 기대한다. 또한 시간적 요소를 추가로 고려한 시공간적 모델

의 개발을 제안한다. SRGCNN-GW 모형을 시간에 따라 연속적으로 쌓은 모형은 시간 변화에 따른 아파트 가격의 동적 변동성을 더욱 정확하게 포착함으로써, 보다 정교하고 현실에 부합하는 예측 결과를 제공할 수 있을 것으로 기대된다. 이러한 접근 방식은 서울시 아파트 매매 가격 예측뿐만 아니라 다양한 시공간 데이터의 예측과 분석에도 응용될 수 있을 것이다.

참고문헌

- [1] Di Zhu, Yu Liu, Xin Yao, and Manfred M.Fischer. Spatial regression graph convolutional neural networks: A deep learning paradigm for spatial multivariate distributions. *Geoinformatica*, 26:645-676, 2018.
- [2] Michaël Defferrard, Xavier Bresson, and Pierre Vandergheynst. Convolutional Neural Networks on Graphs with Fast Localized Spectral Filtering. *Advances in neural information processing systems*, pages 3844–3852, 2016.
- [3] Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. *International Conference on Learning Representations (ICLR)*, 2017.
- [4] Ko, Jong Wan. An Analysis of Determinants of Housing Price Change by Types of Apartment Purchase Market in Seoul. *Korea Real Estate Academy Review*, 58:116-127, 2014.
- [5] Anselin L, Rey SJ, et al. *Perspectives on Spatial Data Analysis*. Springer, 2010.
- [6] Arthur Getis, Jared Aldstadt. Constructing the Spatial Weights Matrix Using a Local Statistic. *Geographical Analysis*, 36(2): 90–104, 2004.
- [7] Subhan Hartanto, Mhd Furqan, Andysah Putera Utama Siahaan and Wirda Fitriani. Haversine Method in Looking for the Nearest Masjid. *International*

- Journal of Recent Trends in Engineering & Research (IJRTER)*, 3(8): 187-195, 2017.
- [8] A. C. Noel Cressie. *Statistics for Spatial Data*. Wiley, 1993.
 - [9] A. C. Noel Cressie, Christopher K. Wikle. *Statistics for Spatio-Temporal Data*. Wiley, 2015.
 - [10] Christopher K. Wikle, Andrew Zammit-Mangion, and Noel Cressie. *Spatio-temporal statistics with R*. Chapman & Hall/CRC, 2019.
 - [11] Chauvet, P. The variogram Cloud. In *Jhonson, T.B. and Barnes, R.J., Eds., 17th APCOM Society of Mining Engineers*, pages 757-764, 1982.
 - [12] A. Stein and L. C. A. Corsten. Universal Kriging and Cokriging as a Regression Procedure. *Biometrics*, 47(2): 575-587, 1991.
 - [13] Wackernagel, H. *Multivariate Geostatistics: An Introduction with Applications*, 2nd ed. Springer, 1998.
 - [14] Matheron, G. Principles of Geostatistics. *Economic Geology*, 58: 1246-1266, 1963.
 - [15] Cressie, N. Fitting variogram models by weighted least squares. *Mathematical Geology*, 17: 563-586, 1985.
 - [16] Ronald Christensen. *Advanced Linear Modeling: Multivariate, Time Series, and Spatial Data; Nonparametric Regression and Response Surface Maximization*. Springer, 2001.
 - [17] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521:436-444, 2015.

- [18] Fischer Manfred M. Computational neural networks: a new paradigm for spatial analysis. *Environment and Planning A: Economy and Space*, 30: 1873–1891, 1998.
- [19] Hao Zhang, Yong Wang. Kriging and cross-validation for massive spatial data. *Environmetrics*, 21: 209-304, 2010.
- [20] Edzer J Pebesma. Multivariable geostatistics in S: the gstat package. *Computers & Geosciences*, 30(7): 683-691, 2004.

Abstract

The sale prices of apartments in Seoul are subject to complex fluctuations driven by various spatiotemporal factors, with geographical location being a primary influence. This study employs the Spatial Regression Graph Convolutional Neural Networks (SRGCNN) and its extension, the Geographically Weighted SRGCNN (SRGCNN-GW), as introduced by Zhu et al. (2022), to capture intricate spatial patterns determined by geographical locations and to forecast the sale prices of apartments in Seoul. The SRGCNN model efficiently learns complex spatial interactions and relationships by representing spatial connectivity in a graph format. Our research takes into account the characteristics of the apartments, spatial factors of their locations, and temporal aspects at the time of transaction for prediction. Additionally, we explore fitting various spatial weight matrices to model the spatial connectivity between apartment listings and seek to identify the most effective spatial weight matrix. Lastly, the validity of the SRGCNN and SRGCNN-GW models is assessed by comparing their performance with traditional spatial data prediction methods, such as kriging.

Keywords: Spatial statistics, SRGCNN, Spatial weights matrix, Spatial data

Student Number: 2022-22742