

고준호 교수님 - 박현근

석사학위논문 심사평

1. 전체 평가

본 논문은 서울시 아파트 매매가격을 대상으로 거리 기반 접근성, 시점 정합 변수, 기계학습 모형, SHAP 분석을 결합하여 가격 예측 구조를 분석하고자 한 연구입니다. 2019~2025년의 대규모 실거래 자료를 활용하고, OLS, Random Forest, XGBoost를 비교하며, 무작위 분할뿐 아니라 시간순 분할과 단지 분할을 함께 제시한 점은 긍정적으로 평가할 수 있습니다.

그러나 현재 원고는 연구의 차별성, 제목과 분석방법의 정합성, SHAP 결과 해석, 정책적 시사점의 수립에서 상당한 보완이 필요합니다. 특히 논문은 “거리 기반 접근성”과 “시공간 이질성”을 핵심으로 제시하고 있으나, 실제 분석은 기존 부동산 가격 예측 연구에서 이미 널리 사용되어 온 기계학습 모형과 개별 단지 기준 근린환경 변수의 적용에 머무르는 부분이 큼니다. 따라서 본 논문은 “서울시 아파트 매매가격의 시공간 이질성을 규명한 연구”라기보다, “서울시 아파트 매매가격 예측에서 거리 기반 근린환경 변수와 시점 정합 자료의 활용 가능성을 탐색한 연구”로 위치를 조정하는 것이 더 적절합니다.

2. 연구 차별성 주장의 전면 재검토 필요

p.19~20의 “선행연구와의 차별성”에서 본 논문은 첫째, “OLS, 랜덤 포레스트, XGBoost의 3모형 비교와 SHAP 기반 해석을 함께 제시”한 점을 차별성으로 제시하고 있습니다.

그러나 머신러닝과 XAI 기법은 이미 부동산 가격 예측 및 대량평가 연구에서 널리 사용되고 있습니다. Random Forest, XGBoost, SHAP을 적용했다는 사실 자체는 더 이상 차별성으로 보기 어렵습니다.

또한 p.19~20에서 둘째 차별성으로 제시한 “법정동 기반 실거래 데이터를 단지 좌표로 정렬하고 각 단지에서 시설까지의 최근접거리와 반경 내 개수를 산출한 점 역시 강한 차별성으로 보기 어렵습니다. 개별 물건, 필지, 단지 또는 거래 좌표를 기준으로 지하철역, 학교, 공원, 상업시설, 도심까지의 거리 또는 반경 내 시설 수를 산출하는 방식은 해도닉 가격모형 연구에서 오래전부터 사용되어 온 일반적인 접근입니다.

따라서 현재 제시된 첫째와 둘째 차별성은 “차별성”이라기보다 기본적인 연구 설계 요소에 가깝습니다. 본 논문에서 상대적으로 차별성으로 주장할 수 있는 부분은 다음에 한정됩니다.

첫째, 시설 정보의 시점 정합성을 고려하려 했다는 점입니다. 둘째, 무작위 분할 외에 시간순 분할과 단지 분할을 통해 예측모형의 일반화 가능성을 검토했다는 점입니다. 셋째, 거리 기반 변수군의 추가가 예측 성능과 변수 기여도에 미치는 영향을 소거분석으로 확인하려 했다는 점입니다.

따라서 차별성 서술은 “머신러닝 적용”과 “개별 단지 기준 변수 구축”이 아니라, “거리 기반 근린환경 변수와 시점 정합 자료를 활용하여 예측모형의 일반화 가능성을 검토하였다”는 방향으로 전면 재작성해야 합니다.

3. ‘시공간 이질성’이라는 제목과 실제 분석의 정합성 문제

논문 제목은 “거리 기반 접근성과 시공간 이질성”을 강조하고 있으나, 현재 분석이 시공간 이질성을 직접 추정하는 구조인지는 불분명합니다. p.54의 “권역별 SHAP 분석 — 강남 3구와 비강남의 구조 차이”, p.57의 “연도별 SHAP 분석 — 시장 국면별 기여도 변동”, p.59의 “연도×권역 교차 SHAP 분석 — 시공간 이질성의 실증”은 모두 흥미로운 시도입니다. 그러나 이 분석들은 모형 내에서 공간적 계수 변화나 시간적 효과 변화를 직접 추정한 것이 아니라, SHAP 값을 집단별로 나누어 사후적으로 비교한 것에 가깝습니다.

특히 p.59의 “연도×권역 교차 SHAP 분석”이라는 표현은 연도와 권역의 상호작용 효과를 직접 분석한 것처럼 보일 수 있습니다. 그러나 실제로 연도×권역 상호작용항을 모형에 명시적으로 포함했거나 SHAP interaction value를 계산한 것이 아니라면, 이는 “교차 분석”이라기보다 “연도-권역별 SHAP 값 비교”입니다. 따라서 “시공간 이질성의 실증”이라는 표현은 과도하며, “연도-권역 조합별 예측 기여도 비교” 정도로 수정하는 것이 적절합니다.

공간적 이질성을 주장하려면 GWR, MGWR, 공간오차모형, 공간지연모형, 지역×변수 상호작용 모형 등이 필요합니다. 시간적 이질성을 주장하려면 연도×변수 상호작용, 패널모형, 반복매매모형, 시점 고정효과 또는 rolling-origin 검증이 더 적절합니다. 현재 분석은 “시공간 이질성 규명”이 아니라 “시공간별 예측 기여도 차이의 탐색”으로 표현을 낮추어야 합니다.

4. 예측모형의 일반화 가능성 분석을 핵심으로 재구성할 필요

p.36의 “모형별 분할별 예측 성능 비교” 표는 매우 중요한 결과입니다. 표에서는 XGBoost가 무작위 분할에서 $R^2=0.927$ 을 보이지만, 단지 분할에서는 $R^2=0.638$, 시간순 분할에서는 $R^2=0.812$ 로 낮아지는 것으로 제시됩니다. 이 결과는 단순히 “XGBoost가

우수하다는 결론보다 훨씬 중요합니다. 즉, 모형은 동일 분포 내 예측에는 강하지만, 보지 못한 단지나 다른 시점에 대한 일반화에는 한계가 있음을 보여줍니다.

따라서 본 논문의 핵심은 SHAP 순위 해석보다 예측모형의 시간적·공간적 일반화 가능성 검토가 되어야 합니다. 특히 p.36의 무작위·단지·시간순 분할 결과와 p.39의 “소거분석 시나리오별 XGBoost R²”는 논문의 가장 중요한 분석으로 재배치할 필요가 있습니다.

더 나아가 특정 기간의 자료로 학습한 모형이 이후 시점의 데이터를 얼마나 잘 예측하는지를 검증하는 expanding window 또는 rolling-origin 검증을 추가하는 것이 바람직합니다. 예를 들어 2019~2021년으로 학습하고 2022년을 예측, 2019~2022년으로 학습하고 2023년을 예측하는 방식입니다. 이 접근은 “시공간 이질성”보다 “예측모형의 시간적 일반화 가능성”이라는 더 명확한 연구 기여를 만들 수 있습니다.

5. 거리 기반 접근성 변수의 의미를 더 엄밀히 해야 함

p.24~25 및 p.33 전후의 변수 설명에서 지하철역 최근접거리, 지하철역 1km 내 개수, 어린이집 1km 내 개수, 학원 1km 내 개수, 백화점 최근접거리, 종합병원 최근접거리, CCTV 500m 내 개수 등이 사용된 것으로 보입니다. 그러나 이러한 변수들은 엄밀한 의미의 접근성이라기보다 직선거리 또는 반경 내 시설 수에 기반한 “거리 기반 근린환경 변수”에 가깝습니다.

따라서 다음 사항을 명확히 해야 합니다.

첫째, 거리가 직선거리인지 네트웍 거리인지 밝혀야 합니다. 둘째, 500m, 1km, 2km 반경 설정의 근거를 제시해야 합니다. 셋째, 최근접거리와 반경 내 개수를 함께 투입할 때 중복 정보 또는 다중공선성 문제가 없는지 검토해야 합니다. 넷째, 시설의 질, 규모, 정원, 서비스 수준, 브랜드 등은 반영하지 못한다는 한계를 명확히 해야 합니다.

특히 어린이집 수, 학원 수, CCTV 수는 시설의 존재량을 나타낼 뿐 실제 이용 가능성이나 질을 의미하지 않습니다. 따라서 “접근성 효과”라는 표현보다 “근린환경 변수의 예측 기여도”라는 표현이 더 적절합니다.

6. 시점 정합 변수 구축은 장점이거나 설명이 부족함

본 논문에서 가장 긍정적으로 볼 수 있는 부분은 시설 정보의 시점 정합성을 고려하려 했다는 점입니다. 현재 시설의 시설 정보를 과거 거리에 일괄 적용하면 시간적 정보 누락이 발생할 수 있기 때문입니다.

그러나 이 부분이 차별성으로 인정되려면 설명이 더 구체적이어야 합니다. 어떤 시설 유형에 대해 개입·폐업 이력을 반영했는지, 어떤 시설은 현재 자료만 사용했는지, 거리일 기준인지 연도 기준인지, 시설 이전이나 명칭 변경은 어떻게 처리했는지 명확히 제시해야 합니다.

또한 p.39의 소거분석에서 “거리 기반 전환”과 “시점 정합”의 기여를 비교하고 있으나, 성능 차이가 변수군 자체의 효과인지, 변수 수 증가 때문인지, 시간적 정보 누락 제거 때문인지 명확히 구분하기 어렵습니다. 소거분석은 비교 조건을 더 엄밀하게 설계하고, 가능하다면 반복 분할 또는 부트스트랩을 통해 성능 차이의 안정성을 제시해야 합니다.

7. SHAP 해석의 수위를 낮추어야 함

p.48의 “전체 SHAP 분석 — 가격 예측 기여 구조”, p.54의 권역별 SHAP 분석, p.57의 연도별 SHAP 분석, p.59의 연도×권역 SHAP 분석은 본 논문의 핵심 결과입니다. 그러나 SHAP은 회귀계수, 탄력성, 인과효과가 아니라 XGBoost 예측값에 대한 변수별 기여도입니다.

따라서 “해당 변수가 가격을 결정한다”, “해당 시설이 가격 프리미엄을 만든다”, “접근성이 가격을 상승시킨다”와 같은 표현은 피해야 합니다. 적절한 표현은 “해당 변수가 XGBoost 예측값 형성에 크게 기여하였다”, “해당 변수는 모형 내에서 높은 예측 기여도를 보였다” 정도입니다.

또한 강남 3구와 비강남, 연도별, 연도×권역별 SHAP 비교에서는 각 집단의 표본 수, 가격 분산, 변수 분포가 다릅니다. 따라서 SHAP 값을 단순 비교하거나 특정 지역에서 특정 변수가 더 강하게 작동한다고 단정해서는 안 됩니다. 이는 “집단별 예측 기여도 차이”로 제한적으로 해석해야 합니다.

9. 강남 3구/비강남 이분법의 한계

p.54의 “권역별 SHAP 분석 — 강남 3구와 비강남의 구조 차이”는 서울 아파트 시장 분석에서 직관적 비교입니다. 그러나 “공간적 이질성”을 주장하기에는 강남 3구와 비강남이라는 이분법은 다소 단순합니다. 비강남 내부에도 마용성, 목동, 여의도, 노도강, 동북권, 서남권 등 가격 구조가 다른 하위시장이 존재합니다.

따라서 강남 3구/비강남 비교는 의미가 있지만, 이를 서울 전체의 공간적 이질성 분석으로 과도하게 일반화해서는 안 됩니다. 가능하다면 서울 5대 생활권, 자치구 그룹,

가격 분위, 또는 데이터 기반 클러스터별 추가 분석을 검토할 필요가 있습니다. 어렵다면 이분법적 구분의 한계를 명확히 밝혀야 합니다.

10. 정책적 시사점은 직접 처방보다 진단 지표 중심으로 완화 필요

본 연구는 예측모형과 SHAP 기반 분석입니다. 따라서 특정 시설이 가격을 올리거나 내린다는 인과효과를 식별한 것은 아닙니다. 학원, 어린이집, 지하철, CCTV, 백화점 등의 SHAP 기여도가 높다고 해서 해당 시설을 확충하거나 이전하면 가격이 변화한다고 말할 수 없습니다.

정책적 시사점은 직접 처방이 아니라 다음 수준으로 제한하는 것이 적절합니다.

첫째, 거리 기반 근린환경 변수는 주택가격 예측과 시장 모니터링에서 진단 지표로 활용될 수 있습니다. 둘째, 시설 정보의 시점 종합성을 반영하지 않으면 가격예측이나 정책평가에서 정보 누출이 발생할 수 있습니다. 셋째, 강남 3구와 비강남은 예측 기여도 구조가 다르게 나타나므로 동일한 해석을 적용하기 어렵습니다. 넷째, 실제 정책효과를 보려면 시설 신설, 노선 개통, 규제 변화 등 외생적 충격을 활용한 인과분석이 필요합니다.